



ΔΗΜΟΚΡΙΤΕΙΟ
ΠΑΝΕΠΙΣΤΗΜΙΟ
ΘΡΑΚΗΣ

ΤΜΗΜΑ
ΗΜ&ΜΥ

Αναγνώριση Προτύπων

2023-2024

ΗΩ01 - Εργασία 1

Ονοματεπώνυμο: Δημήτριος Αναστασούδης
ΑΕΜ: 58085

Άσκηση 1.

1. Έστω ότι θέλετε να κατασκευάσετε ένα σύστημα που ταξινομεί email σε τρεις κατηγορίες {n:Normal, s:Spam, m:Malicious}. Έχετε στη διάθεσή σας έναν αλγόριθμο που διαβάζει τα περιεχόμενα κάθε email και βαθμολογεί την επικινδυνότητά του D σε πέντε στάθμες από το 1 έως το 5. Χρησιμοποιώντας έναν μεγάλο όγκο επισημασμένων email, μπορείτε να υπολογίσετε την κατανομή της εκτιμηθείσας επικινδυνότητας για καθεμία από τις κατηγορίες email, η οποία δίδεται από τον ακόλουθο πίνακα:

	Normal	Spam	Malicious
D=1	0.5	0.05	0.02
D=2	0.23	0.15	0.13
D=3	0.16	0.4	0.15
D=4	0.1	0.3	0.3
D=5	0.01	0.1	0.4

Δεδομένου ότι για τις a priori πιθανότητες των κλάσεων γνωρίζετε ότι $P(s)=0.3$ και $P(m)=0.1$, να υπολογίσετε:

- Την απόφαση που θα παίρνει το σύστημα για κάθε πιθανή τιμή D με βάση τον κανόνα απόφασης Bayes.
- Το ολικό σφάλμα ταξινόμησης.
- Το ολικό σφάλμα ταξινόμησης στην περίπτωση που δεν γνωρίζατε τίποτα για τις a priori πιθανότητες των κλάσεων (τις θεωρούσατε ισοπίθανες).

α)

Αρχικά, σύμφωνα με τα δεδομένα, $P(s) = 0.3$ και $P(m) = 0.1$. Οπότε μπορούμε να υπολογίσουμε το $P(n)$ με τον εξής τύπο:

$$P(n) = 1 - P(s) - P(m) = 1 - 0.3 - 0.1 = 0.6$$

Αυτό, προκύπτει καθώς το άθροισμα όλων των πιθανοτήτων πρέπει να ισούται πάντα με 1.

Τώρα, για να βρούμε την απόφαση που θα παίρνει το σύστημα κάθε φορά, σύμφωνα με τον κανόνα απόφασης Bayes, θα χρησιμοποιήσουμε τον παρακάτω τύπο, για τον υπολογισμό των επιμέρους πιθανοτήτων:

$$P(\omega_j | x) = \frac{P(x | \omega_j) \cdot P(\omega_j)}{\sum_i P(x | \omega_i) \cdot P(\omega_i)}$$

1. Για $D=1$:

- a. Αρχικά, θα υπολογίσουμε τον παρονομαστή που θα είναι κοινός σε όλα,

δηλαδή το άθροισμά $\sum_i P(D = 1 | \omega_i) \cdot P(\omega_i)$

$$\begin{aligned} \sum_i P(D = 1 | \omega_i) \cdot P(\omega_i) &= P(D = 1 | n) \cdot P(n) + P(D = 1 | s) \cdot P(s) + P(D = 1 | m) \cdot P(m) = \\ &= 0.5 \cdot 0.6 + 0.05 \cdot 0.3 + 0.02 \cdot 0.1 = 0.317 \end{aligned}$$

- b. Πιθανότητα το Email να είναι Normal:

$$P(n | D = 1) = \frac{P(D = 1 | n) \cdot P(n)}{\sum_i P(D = 1 | \omega_i) \cdot P(\omega_i)} = \frac{0.5 \cdot 0.6}{0.317} = 0.9463$$

- c. Πιθανότητα το Email να είναι Spam:

$$P(s | D = 1) = \frac{P(D = 1 | s) \cdot P(s)}{\sum_i P(D = 1 | \omega_i) \cdot P(\omega_i)} = \frac{0.05 \cdot 0.3}{0.317} = 0.0473$$

- d. Πιθανότητα το Email να είναι Malicious:

$$P(m | D = 1) = \frac{P(D = 1 | m) \cdot P(m)}{\sum_i P(D = 1 | \omega_i) \cdot P(\omega_i)} = \frac{0.02 \cdot 0.1}{0.317} = 0.0063$$

2. Για $D=2$:

- a. Αρχικά, θα υπολογίσουμε τον παρονομαστή που θα είναι κοινός σε όλα,

δηλαδή το άθροισμά $\sum_i P(D = 2 | \omega_i) \cdot P(\omega_i)$

$$\begin{aligned} \sum_i P(D = 2 | \omega_i) \cdot P(\omega_i) &= P(D = 2 | n) \cdot P(n) + P(D = 2 | s) \cdot P(s) + P(D = 2 | m) \cdot P(m) = \\ &= 0.23 \cdot 0.6 + 0.15 \cdot 0.3 + 0.13 \cdot 0.1 = 0.196 \end{aligned}$$

- b. Πιθανότητα το Email να είναι Normal:

$$P(n | D = 2) = \frac{P(D = 2 | n) \cdot P(n)}{\sum_i P(D = 2 | \omega_i) \cdot P(\omega_i)} = \frac{0.23 \cdot 0.6}{0.196} = 0.704$$

- c. Πιθανότητα το Email να είναι Spam:

$$P(s | D = 2) = \frac{P(D = 2 | s) \cdot P(s)}{\sum_i P(D = 2 | \omega_i) \cdot P(\omega_i)} = \frac{0.15 \cdot 0.3}{0.196} = 0.2295$$

- d. Πιθανότητα το Email να είναι Malicious:

$$P(m | D = 2) = \frac{P(D = 2 | m) \cdot P(m)}{\sum_i P(D = 2 | \omega_i) \cdot P(\omega_i)} = \frac{0.13 \cdot 0.1}{0.196} = 0.663$$

3. Για **D=3**:

a. Αρχικά, θα υπολογίσουμε τον παρονομαστή που θα είναι κοινός σε όλα,

$$\text{δηλαδή το άθροισμά } \sum_i P(D = 3 | \omega_i) \cdot P(\omega_i)$$

$$\begin{aligned} \sum_i P(D = 3 | \omega_i) \cdot P(\omega_i) &= P(D = 3 | n) \cdot P(n) + P(D = 3 | s) \cdot P(s) + P(D = 3 | m) \cdot P(m) = \\ &= 0.16 \cdot 0.6 + 0.4 \cdot 0.3 + 0.15 \cdot 0.1 = 0.231 \end{aligned}$$

b. Πιθανότητα το Email να είναι Normal:

$$P(n | D = 3) = \frac{P(D = 3 | n) \cdot P(n)}{\sum_i P(D = 3 | \omega_i) \cdot P(\omega_i)} = \frac{0.16 \cdot 0.6}{0.231} = 0.4155$$

c. Πιθανότητα το Email να είναι Spam:

$$P(s | D = 3) = \frac{P(D = 3 | s) \cdot P(s)}{\sum_i P(D = 3 | \omega_i) \cdot P(\omega_i)} = \frac{0.4 \cdot 0.3}{0.231} = 0.5194$$

d. Πιθανότητα το Email να είναι Malicious:

$$P(m | D = 3) = \frac{P(D = 3 | m) \cdot P(m)}{\sum_i P(D = 3 | \omega_i) \cdot P(\omega_i)} = \frac{0.15 \cdot 0.1}{0.231} = 0.065$$

4. Για **D=4**:

a. Αρχικά, θα υπολογίσουμε τον παρονομαστή που θα είναι κοινός σε όλα,

$$\text{δηλαδή το άθροισμά } \sum_i P(D = 4 | \omega_i) \cdot P(\omega_i)$$

$$\begin{aligned} \sum_i P(D = 4 | \omega_i) \cdot P(\omega_i) &= P(D = 4 | n) \cdot P(n) + P(D = 4 | s) \cdot P(s) + P(D = 4 | m) \cdot P(m) = \\ &= 0.1 \cdot 0.6 + 0.3 \cdot 0.3 + 0.3 \cdot 0.1 = 0.18 \end{aligned}$$

b. Πιθανότητα το Email να είναι Normal:

$$P(n | D = 4) = \frac{P(D = 4 | n) \cdot P(n)}{\sum_i P(D = 4 | \omega_i) \cdot P(\omega_i)} = \frac{0.1 \cdot 0.6}{0.18} = 0.3333$$

c. Πιθανότητα το Email να είναι Spam:

$$P(s | D = 4) = \frac{P(D = 4 | s) \cdot P(s)}{\sum_i P(D = 4 | \omega_i) \cdot P(\omega_i)} = \frac{0.3 \cdot 0.3}{0.18} = 0.5$$

d. Πιθανότητα το Email να είναι Malicious:

$$P(m | D = 4) = \frac{P(D = 4 | m) \cdot P(m)}{\sum_i P(D = 4 | \omega_i) \cdot P(\omega_i)} = \frac{0.3 \cdot 0.1}{0.18} = 0.1666$$

5. Για **D=5**:

a. Αρχικά, θα υπολογίσουμε τον παρονομαστή που θα είναι κοινός σε όλα,

$$\sum_i P(D = 5 | \omega_i) \cdot P(\omega_i)$$

δηλαδή το άθροισμά

$$\begin{aligned} \sum_i P(D = 5 | \omega_i) \cdot P(\omega_i) &= P(D = 5 | n) \cdot P(n) + P(D = 5 | s) \cdot P(s) + P(D = 5 | m) \cdot P(m) = \\ &= 0.01 \cdot 0.6 + 0.1 \cdot 0.3 + 0.4 \cdot 0.1 = 0.076 \end{aligned}$$

b. Πιθανότητα το Email να είναι Normal:

$$P(n | D = 5) = \frac{P(D = 5 | n) \cdot P(n)}{\sum_i P(D = 5 | \omega_i) \cdot P(\omega_i)} = \frac{0.01 \cdot 0.6}{0.076} = 0.0789$$

c. Πιθανότητα το Email να είναι Spam:

$$P(s | D = 5) = \frac{P(D = 5 | s) \cdot P(s)}{\sum_i P(D = 5 | \omega_i) \cdot P(\omega_i)} = \frac{0.1 \cdot 0.3}{0.076} = 0.3947$$

d. Πιθανότητα το Email να είναι Malicious:

$$P(m | D = 5) = \frac{P(D = 5 | m) \cdot P(m)}{\sum_i P(D = 5 | \omega_i) \cdot P(\omega_i)} = \frac{0.4 \cdot 0.1}{0.076} = 0.5263$$

Μπορούμε να βάλουμε όλες τις παραπάνω πιθανότητες σε ένα πίνακα για να τις έχουμε πιο οργανωμένες.

	Normal	Spam	Malicious
D=1	0.9463	0.0473	0.063
D=2	0.704	0.2295	0.065
D=3	0.4155	0.5194	0.065
D=4	0.3333	0.5	0.1666
D=5	0.0789	0.3947	0.5263

Σύμφωνα με τις παραπάνω πιθανότητες, αλλά και τον κανόνα απόφασης του Bayes, το σύστημα θα παίρνει την απόφαση με την μεγαλύτερη πιθανότητα, για κάθε D . Δηλαδή, το

$\max[P(n | D), P(s | D), P(m | D)]$. Στην δική μας περίπτωση, είναι τα εξής:

1. Για $D=1$: Το Email θα θεωρηθεί **Normal**
2. Για $D=2$: Το Email θα θεωρηθεί **Normal**
3. Για $D=3$: Το Email θα θεωρηθεί **Spam**
4. Για $D=4$: Το Email θα θεωρηθεί **Spam**
5. Για $D=5$: Το Email θα θεωρηθεί **Malicious**

β)

Για να υπολογίσουμε το ολικό σφάλμα, θα χρησιμοποιήσουμε τον τύπο:

$$P_{e,total} = \sum_i P(x_i)P_e(x_i), x_i = D,$$

$$, P_e(x_i) = 1 - \max[P(\omega_i | x_i)]$$

Επίσης, ισχύει ότι

$$P(D) = \sum_i P(D | \omega_i) \cdot P(\omega_i)$$

Οπότε, έχουμε ότι:

$$\begin{aligned} P_{e,total} &= P(D=1) \cdot (1 - P(n | D=1)) + P(D=2) \cdot (1 - P(n | D=2)) + \\ &+ P(D=3) \cdot (1 - P(s | D=3)) + P(D=4) \cdot (1 - P(4)) + P(D=5) \cdot (1 - P(m | D=5)) = \\ &= 0.317 \cdot (1 - 0.9463) + 0.196 \cdot (1 - 0.704) + 0.231 \cdot (1 - 0.5194) + \\ &+ 0.18 \cdot (1 - 0.5) + 0.076 \cdot (1 - 0.5263) = 0.017 + 0.058 + 0.111 + 0.09 + 0.036 = 0.312 \end{aligned}$$

γ)

Αν δεν γνωρίζουμε κάτι για τις a priori πιθανότητες, και τις θεωρήσουμε ισοπίθανες, θα ισχύει ότι

$P(n) = P(m) = P(s) = 0.33$. Αυτό, θα επηρεάσει τις αποφάσεις που θα παίρνει το σύστημα, καθώς θα αλλάξει τον κανόνα απόφασης του Bayes. Αυτός, βέβαια μπορεί να απλοποιηθεί

στον παρακάτω:

$$P(\omega_j | x) = \frac{P(x | \omega_j) \cdot P(\omega_j)}{\sum_i P(x | \omega_i) \cdot P(\omega_i)} = \frac{P(x | \omega_j)}{\sum_i P(x | \omega_i)},$$

καθώς απλοποιούνται οι a priori πιθανότητες.

Επιπλέον, παρατηρούμε ότι εφόσον το prior αλλά και το evidence είναι ίδιο σε όλες τις περιπτώσεις, η posterior πιθανότητα που μας ενδιαφέρει, δηλαδή η μέγιστη, σε κάθε περίπτωση, θα είναι αυτή με το μεγαλύτερο likelihood. Δηλαδή:

1. Για $D=1$: Σύμφωνα με το likelihood, το Email θα θεωρηθεί **Normal** με:

$$P(n | D = 1) = \frac{P(D = 1 | n)}{\sum_i P(D = 1 | \omega_i)} = \frac{0.5}{0.5 + 0.05 + 0.02} = 0.8771$$

2. Για **D=2**: Σύμφωνα με το likelihood, το Email θα θεωρηθεί **Normal** με:

$$P(n | D = 2) = \frac{P(D = 2 | n)}{\sum_i P(D = 2 | \omega_i)} = \frac{0.23}{0.23 + 0.15 + 0.13} = 0.45$$

3. Για **D=3**: Σύμφωνα με το likelihood, το Email θα θεωρηθεί **Spam** με:

$$P(s | D = 3) = \frac{P(D = 3 | s)}{\sum_i P(D = 3 | \omega_i)} = \frac{0.4}{0.16 + 0.4 + 0.15} = 0.5633$$

4. Για **D=4**: Σύμφωνα με το likelihood, το Email θα θεωρηθεί **Spam ή Malicious** με:

$$P(s | D = 4) = \frac{P(D = 4 | s)}{\sum_i P(D = 4 | \omega_i)} = \frac{0.3}{0.1 + 0.3 + 0.3} = 0.4285$$

5. Για **D=5**: Σύμφωνα με το likelihood, το Email θα θεωρηθεί **Malicious** με:

$$P(m | D = 5) = \frac{P(D = 5 | m)}{\sum_i P(D = 5 | \omega_i)} = \frac{0.4}{0.01 + 0.1 + 0.4} = 0.7843$$

Οπότε το ολικό σφάλμα ταξινόμησης είναι όπως και προηγουμένως:

$$P_{e,total} = \sum_i P(x_i) P_e(x_i), x_i = D,$$

$$, P_e(x_i) = 1 - \max[P(\omega_i | x_i)]$$

$$P(D) = \sum_i P(D | \omega_i) \cdot P(\omega_i)$$

Επίσης, ισχύει ότι

Τέλος, βγάζοντας και ως κοινό παράγοντα μπροστά το prior έχουμε ότι:

$$\begin{aligned} P_{e,total} &= 0.33 \cdot P(D = 1) \cdot (1 - P(n | D = 1)) + 0.33 \cdot P(D = 2) \cdot (1 - P(n | D = 2)) + \\ &+ 0.33 \cdot P(D = 3) \cdot (1 - P(s | D = 3)) + 0.33 \cdot P(D = 4) \cdot (1 - P(4)) + \\ &+ 0.33 \cdot P(D = 5) \cdot (1 - P(m | D = 5)) = \\ &= 0.33 \cdot [0.57 \cdot (1 - 0.8771) + 0.51 \cdot (1 - 0.45) + 0.71 \cdot (1 - 0.5633) + 0.7 \cdot (1 - 0.4285) + 0.51 \cdot (1 - 0.7843)] = \\ &= 0.33 \cdot (0.07 + 0.28 + 0.31 + 0.4 + 0.11) = 0.3861 \end{aligned}$$

Άσκηση 2.

2. Για ένα πρόβλημα ταξινόμησης 2 κλάσεων $\Omega = \{\omega_1, \omega_2\}$, όπου $P(x|\omega_1) = N(2, 0.5)$ και $P(x|\omega_2) = N(1.8, 0.2)$, με εκ των προτέρων πιθανότητα $P(\omega_1) = 1/4$, όπου το κόστος έχει

$$\text{ορισθεί ως } \lambda = \begin{bmatrix} \lambda_{11} & \lambda_{12} \\ \lambda_{21} & \lambda_{22} \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 3 & 0 \end{bmatrix}$$

α) Να βρεθεί η βέλτιστη λύση (κανόνας απόφασης) και να υπολογισθεί το ολικό κόστος.

β) Να προσομοιωθεί η διαδικασία υπολογιστικά, δημιουργώντας τυχαία δείγματα που ακολουθούν την κανονική κατανομή, και να εκτιμηθεί αριθμητικά το κόστος από την λύση (α).

α)

Αρχικά, σύμφωνα με τα δεδομένα της άσκησης, έχουμε:

$$P(\omega_1) + P(\omega_2) = 1 \implies P(\omega_2) = \frac{3}{4}$$

- Για την κλάση ω_1 ισχύει:

$$P(x|\omega_1) = \frac{1}{\sqrt{2\pi \cdot 0.5}} \cdot e^{\frac{-(x-2)^2}{2 \cdot 0.5}} = \frac{1}{\sqrt{\pi}} \cdot e^{-(x-2)^2}$$

- Για την κλάση ω_2 ισχύει:

$$P(x|\omega_2) = \frac{1}{\sqrt{2\pi \cdot 0.2}} \cdot e^{\frac{-(x-1.8)^2}{2 \cdot 0.2}} = \frac{1}{\sqrt{0.4 \cdot \pi}} \cdot e^{\frac{-(x-1.8)^2}{0.4}}$$

Σύμφωνα με τον Bayes, παίρνουμε την παρακάτω ανισότητα, με επιλεγμένη κλάση την ω_1 :

$$\begin{aligned} \frac{P(x|\omega_1)}{P(x|\omega_2)} &\geq \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \cdot \frac{P(\omega_2)}{P(\omega_1)} \implies \frac{\frac{1}{\sqrt{\pi}} \cdot e^{-(x-2)^2}}{\frac{1}{\sqrt{0.4 \cdot \pi}} \cdot e^{\frac{-(x-1.8)^2}{0.4}}} \geq \frac{1}{3} \cdot \frac{\frac{3}{4}}{\frac{1}{4}} \implies \\ &\implies e^{\frac{(x-1.8)^2 - 0.4 \cdot (x-2)^2}{0.4}} \geq \sqrt{0.4} \implies (x-1.8)^2 - 0.4 \cdot (x-2)^2 \geq 0.4 \cdot \ln \sqrt{0.4} \implies \\ &\implies x^2 - 2 \cdot 1.8 \cdot x + 1.8^2 - 0.4 \cdot x^2 + 0.4 \cdot 2 \cdot x - 0.4 \cdot 4 - 0.4 \cdot \ln \sqrt{0.4} \geq 0 \implies \\ &\implies 0.6 \cdot x^2 - 2 \cdot x + 1.64 - 0.2 \cdot \ln 0.4 \geq 0 \implies \\ &\implies x^2 - 3.33 \cdot x + 2.73 - 0.33 \cdot \ln 0.4 \geq 0 \implies \\ &\implies x^2 - 3.33 \cdot x + 3.03 \geq 0 \end{aligned}$$

(κάπου έχει γίνει λάθος), για να ισχύει αυτή η ανισότητα ωστόσο, το x πρέπει να παίρνει αυτές τις συγκεκριμένες τιμές)

Εφόσον βρίσκουμε αυτές τις τιμές, το ολικό κόστος υπολογίζεται με τον τύπο:

$$R = \int_{-\infty}^{x_1} \lambda_{21} \cdot P(\omega_2) \cdot P(x|\omega_1) dx + \int_{x_2}^{+\infty} \lambda_{12} \cdot P(\omega_1) \cdot P(x|\omega_2) dx$$

β)

```

1 - P = [0.25, 0.75; 0.4, 0.6]; % Πίνακας πιθανοτήτων μετάβασης
2 - N = 1000; % Αριθμός επαναλήψεων προσομοίωσης
3 - total_cost = 0;
4
5 % Καταστάσεις και κόστη για κάθε κατάσταση
6 - states = [1, 2];
7 - cost_state1 = [0, 1];
8 - cost_state2 = [3, 0];
9
10 - current_state = 1;
11 - for i = 1:N
12 -     if current_state == 1
13 -         transition = rand < P(1,1); % Απόφαση για τη μετάβαση
14 -         total_cost = total_cost + cost_state1(transition + 1); % Ενημέρωση ολικού κόστους
15 -         current_state = 2 - transition; % Ενημέρωση της κατάστασης
16 -     else
17 -         transition = rand < P(2,1);
18 -         total_cost = total_cost + cost_state2(transition + 1); % Ενημέρωση ολικού κόστους
19 -         current_state = transition + 1; % Ενημέρωση της κατάστασης
20 -     end
21 - end
22 % Εμφάνιση του ολικού κόστους
23 - fprintf('Το ολικό κόστος από την προσομοίωση είναι: %d\n', total_cost);

```

Άσκηση 3)

3. Με στόχο την ταξινόμηση δεδομένων με Bayesian κριτήρια, να εκτελεστούν τα παρακάτω βήματα:

α) Να υλοποιήσετε τρεις συναρτήσεις στη γλώσσα προγραμματισμού της αρεσκείας σας που να υπολογίζουν:

- i. Την τιμή της συνάρτησης διάκρισης της μορφής

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln(|\boldsymbol{\Sigma}_i|) + \ln(P(\omega_i))$$

για μια δεδομένη κανονική κατανομή $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ d διαστάσεων και εκ των προτέρων πιθανότητα $P(\omega_i)$.

- ii. Την Ευκλείδεια απόσταση μεταξύ δύο αυθαίρετων σημείων $\mathbf{x}_1$ και $\mathbf{x}_2$ σε χώρο d διαστάσεων.

- iii. Την απόστασης Mahalanobis μεταξύ του μέσου $\boldsymbol{\mu}$ και ενός αυθαίρετου σημείου $\mathbf{x}$ σε χώρο d διαστάσεων, δεδομένου του πίνακα συνδιασποράς $\boldsymbol{\Sigma}$.

β) Να κατεβάσετε από εδώ το αρχείο δεδομένων που περιέχει δεδομένα από 3 κλάσεις ω_i , $i=1,2,3$ και τρία χαρακτηριστικά x_i , $i=1,2,3$. Υποθέτοντας πως οι υποκείμενες κατανομές των κλάσεων είναι Gaussian, να κάνετε εκτίμηση των παραμέτρων των κατανομών με τη μέθοδο της μεγίστης πιθανοφάνειας για τις περιπτώσεις που χρησιμοποιείται μόνο το πρώτο χαρακτηριστικό x_1 , το πρώτο και το δεύτερο χαρακτηριστικό (x_1 και x_2) και τέλος για όλα τα χαρακτηριστικά.

γ) Αφού επιλέξετε τον κατάλληλο ταξινομητή (αιτιολογώντας την επιλογή σας) προσδιορίζεται υπολογιστικά το εμπειρικό σφάλμα ταξινόμησης, δηλαδή το ποσοστό των σημείων που ταξινομείται εσφαλμένα, υποθέτοντας ότι οι a priori πιθανότητες είναι $P(\omega_1) = P(\omega_2) = \frac{1}{2}$, κάνοντας χρήση μόνο του πρώτου χαρακτηριστικού x_1 .

δ) Επαναλάβετε το προηγούμενο βήμα χρησιμοποιώντας πρώτα δύο χαρακτηριστικά (x_1 και x_2) και τέλος όλα τα χαρακτηριστικά. Σχολιάστε τα αποτελέσματά σας και ιδιαίτερα τη σχέση του εμπειρικού σφάλματος με τις διαστάσεις του προβλήματος.

ε) Επαναλάβετε την εκτίμηση του σφάλματος χρησιμοποιώντας όλα τα χαρακτηριστικά για $P(\omega_1) = 0.8$ και $P(\omega_2) = P(\omega_3) = 0.1$. Σε ποια περίπτωση μπορούμε να χρησιμοποιήσουμε καθέναν από τους ταξινομητές που υλοποιήσατε στο βήμα (α);

α)

```
% Συνάρτηση διάκρισης για την κανονική κατανομή
function g = discriminantFunction(x, mu, Sigma, P)
    % x: διάνυσμα σημείου προς ταξινόμηση
    % mu: διάνυσμα μέσου της κατανομής
    % Sigma: πίνακας συνδιασποράς
    % P: πιθανότητα της κλάσης (προ-εκτίμηση)

    d = length(mu); % διαστάσεις του διανύσματος
    term1 = -0.5 * (x - mu)' * inv(Sigma) * (x - mu);
    term2 = -d/2 * log(2 * pi);
    term3 = -0.5 * log(det(Sigma));
    term4 = log(P);

    g = term1 + term2 + term3 + term4;
end
```

```
% Ευκλείδεια απόσταση μεταξύ δύο σημείων
function d = euclideanDistance(x1, x2)
    % x1: διάνυσμα του πρώτου σημείου
    % x2: διάνυσμα του δεύτερου σημείου

    d = sqrt(sum((x1 - x2).^2));
end
```

```
% Απόσταση Mahalanobis
function d = mahalanobisDistance(x, mu, Sigma)
    % x: διάνυσμα του σημείου
    % mu: διάνυσμα μέσου του συνόλου
    % Sigma: πίνακας συνδιασποράς του συνόλου

    d = sqrt((x - mu)' * inv(Sigma) * (x - mu));
end
```

Άσκηση 4.

4. Έστω ότι σχεδιάζετε ένα Bayesian σύστημα ταξινόμησης σε 2 κλάσεις $\omega = \{\omega_1, \omega_2\}$, και καταλήγετε πως η πιθανότητα σφάλματος του συστήματος εξαρτάται από την a priori πιθανότητα P_1 της κλάσης ω_1 σύμφωνα με τη σχέση:

$$P_{error}(p_1) = p_1^2(1 - p_1), \quad 0 \leq p_1 \leq 1$$

- α) Εάν δεν γνωρίζετε το P_1 , για ποια τιμή του θα πρέπει να σχεδιάσετε τα όρια απόφασης του συστήματός σας ώστε να ελαχιστοποιήσετε το μέγιστο πιθανό σφάλμα, και ποια θα είναι η πιθανότητα σφάλματος στην περίπτωση αυτή;
 β) Εάν ρυθμίσετε το σύστημά σας υποθέτοντας πιθανότητα $P_1=0.3$, ποια θα είναι η πιθανότητα σφάλματος εάν η πραγματική a priori πιθανότητα της κλάσης ω_1 είναι $P_1=0.7$;

α)

Καθώς δεν γνωρίζουμε την τιμή του p_1 , για να βεβαιωθούμε ότι για οποιοδήποτε p_1 , θα έχουμε το ίδιο κόστος, και για να θέσουμε τα καλύτερα δυνατά expectations κατά την λειτουργία του συστήματος ταξινόμησης, θα διαλέξουμε την τιμή p_1 , που στην οποία θα είναι μέγιστη η πιθανότητα σφάλματος $P_{error}(p_1)$.

Ισχύει ότι: $P_{error}(p_1) = p_1^2 \cdot (1 - p_1) = p_1^2 - p_1^3$

Επίσης ισχύει ότι: $P'_{error}(p_1) = 2p_1 - 3p_1^2$ και $P''_{error}(p_1) = 2 - 6p_1$

1. Πιθανά τοπικά ακρότατα:

$$P'_{error}(p_1) = 0 \implies 2p_1 - 3p_1^2 = 0 \implies p_1(2 - 3p_1) = 0$$

$$\text{Άρα } p_1 = 0 \text{ ή } p_1 = \frac{2}{3} = 0.66$$

2. Καμπυλότητα:

$$P''_{error}(p_1) > 0 \implies 2 - 6p_1 > 0 \implies p_1 < \frac{1}{3}$$

$$P''_{error}(p_1) < 0 \implies p_1 > \frac{1}{3}$$

Από το 1. και 2. , καταλαβαίνουμε ότι το $P_{error}(p_1)$ γίνεται μέγιστο για $p_1 = 0.66$ με τιμή $P_{error}(0.66) = 0.1481$

β)

Αρχικά, πρέπει να βρούμε την ευθεία που μας ενδιαφέρει να ορίσουμε. Αυτή, θα είναι της μορφής

$$y = ax + b$$

Μπορούμε να βρούμε την κλίση στο σημείο 0.3 από τον τύπο:

$$P'_{error}(0.3) = 2 \cdot 0.33 - 3 \cdot 0.33^2 = 0.33$$

Επίσης, ισχύει $P_{error}(0.3) = 0.3^2 - 0.3^3 = 0.063$


Οπότε, αντικαθιστώντας βρίσκουμε:

$$y = ax + b \implies b = y - ax = 0.063 - 0.33 \cdot 0.3 = -0.036$$

Άρα, η ευθεία είναι η $y = 0.33x - 0.036$

Για $p_1 = 0.7$ που θα είναι επίσης σημείο της ευθείας, θα έχουμε $y = 0.33 \cdot 0.7 - 0.036 = 0.195$

Αυτό, σημαίνει ότι το $P_{error}(0.7) = 0.195$



Άσκηση 5.

5. Αναδρομική εκτίμηση Bayes: Πετάμε ένα νόμισμα $N=10$ φορές και φέρνουμε κατά σειρά $\{\kappa, \gamma, \kappa, \kappa, \kappa, \gamma, \kappa, \kappa, \gamma, \kappa\}$ (κ =κεφάλι, γ =γράμματα). Ποια είναι η πιθανότητα θ να φέρουμε κεφάλι; Η αρχική κατανομή του θ είναι $p(\theta | D^0) = A \cdot \theta(1-\theta)^4$, για $0 \leq \theta \leq 1$ (beta distribution). Ζητείται:
- Να υπολογισθεί το A .
 - Να σχεδιασθούν σε κοινό διάγραμμα τα $p(\theta | D^1)$, $p(\theta | D^5)$, $p(\theta | D^{10})$
 - Να βρεθεί (αριθμητικά) το $p(x = \gamma | D^{10})$ μετά τη 10^η ρίψη.

Εφόσον στο πρώτο κομμάτι της εκφώνησης, δεν αναφέρεται η αρχική κατανομή, για να υπολογίσουμε την πιθανότητα θ να φέρουμε κεφάλι, θα υποθέσουμε ότι η prior πιθανότητα είναι ομοιόμορφη, δηλαδή το $P(\theta)$ είναι σταθερό. Καθώς σύμφωνα με τον κανόνα του Bayes, και με ίσο prior, οι όροι απλοποιούνται, η posterior πιθανότητα θα είναι ανάλογη του likelihood.

Μπορούμε επιπλέον να εκτιμήσουμε ότι έχουμε μια binomial distribution (Beta distribution στην δική μας περίπτωση), με 7 κεφάλια και 3 γράμματα. Δηλαδή, οι παράμετροι είναι:

$$a = k + 1 = 7 + 1 = 8 \text{ και } b = n - k + 1 = 3 + 1 = 4$$

Η πιθανότητα θ να φέρουμε κεφάλι είναι η μέση τιμή της Beta distribution μας, η οποία βγαίνει από τον τύπο:


$$E[\theta] = \frac{a}{a+b} = \frac{8}{12} = 0.66$$

α)

Για να βρούμε την τιμή του A, παίρνουμε το ολοκλήρωμα της αρχικής κατανομής μας, από το 0 έως το 1, το οποίο ισούται με 1.

$$\begin{aligned} \int_0^1 A\theta(1-\theta)^4 d\theta &= 1 \implies A \int_0^1 (\theta - 4\theta^2 + 6\theta^3 - 4\theta^4 + \theta^5) d\theta = 1 \\ \implies A \cdot \left(\frac{1}{2} - \frac{4}{3} + \frac{6}{4} - \frac{4}{5} + \frac{1}{6} \right) &= 1 \\ \implies A \cdot \left(\frac{15 - 40 + 45 - 24 + 5}{30} \right) &= 1 \\ \implies A \cdot \frac{1}{30} = 1 \implies A &= 30 \end{aligned}$$

β)



γ)

Όπως αναφέραμε και στην αρχή, η κατανομή είναι Beta, με καινούργιες παραμέτρους(που έχουν να κάνουν με την αρχική κατανομή τις εξής:

$$a' = 4 + 7 = 11 \text{ και } b' = 1 + 3 = 4$$

Αυτό που ψάχνουμε εμείς, είναι ουσιαστικά το

$$E(1 - \theta) = 1 - E(\theta) = 1 - \frac{a}{a + b} = 1 - \frac{11}{15} = \frac{4}{15} = 0.266$$